

Web Semántica y Datos Abiertos (MTI-453)

Tarea 1

**Universidad Técnica Federico Santa María
MTI-2024**

**Docente: José Emilio Labra
Integrantes: Basso, Felipe
Menesse, Guillermo
Vega, Igor**

20 de marzo de 2026



Tabla de Contenidos

Tarea 1	3
Introducción.....	3
Fuente de Datos.....	3
Proceso de transformación a RDF	4
Modelo de datos RDF	4
Validación con ShEx.....	5
Demostración con datos incorrectos.....	5
SHACL	5
Conclusión	6
Anexos / artefactos entregados	6

Tarea 1

Introducción

La presente tarea aborda la construcción y validación de grafos de datos en formato RDF utilizando un caso de estudio ficticio basado en la empresa MultiSolve, dedicada a servicios de mantenimiento, reparación y atención de requerimientos en edificios, comunidades y domicilios. El objetivo principal es modelar un subconjunto representativo de los datos operacionales de la empresa, complementarlos con un conjunto de datos abiertos de comunas de Chile y definir un modelo de validación mediante Shape Expressions (ShEx) y, opcionalmente, SHACL.

Este enfoque permite ilustrar de manera integrada los conceptos fundamentales de la Web Semántica, incluyendo el diseño de vocabularios, la transformación de fuentes heterogéneas a RDF y la aplicación de mecanismos formales de validación de grafos. La elección del dominio MultiSolve resulta adecuada para la asignatura, ya que combina entidades y relaciones propias de un escenario realista de gestión de órdenes de servicio con la necesidad de reutilizar datos territoriales externos, lo que favorece el análisis crítico de decisiones de modelado y la evaluación de su corrección mediante herramientas estándar.

Para la construcción del grafo privado se definió un dataset sintético que emula datos internos de MultiSolve, incluyendo clientes, domicilios, técnicos, tipos de servicio, equipos y órdenes de servicio. Estos datos se modelaron a partir de la estructura lógica habitual en sistemas de gestión de mantenimiento, con tablas para clientes, domicilios, técnicos, tipos de servicio, equipos y relaciones entre órdenes, técnicos y equipos. Dado que en un contexto real estos datos serían sensibles, se decidió trabajar exclusivamente con identificadores y valores ficticios, evitando el uso de RUT, direcciones reales o cualquier información personal que pudiera asociarse a individuos o entidades específicas.

Como complemento, se seleccionó un conjunto de datos abiertos de comunas de Chile, disponible en formato CSV, que proporciona códigos y nombres de comunas definidos por la institucionalidad nacional. Este dataset no se encuentra originalmente en formato RDF y, por tanto, exige un proceso explícito de transformación y modelado semántico. La integración entre ambos conjuntos se realiza a través del código de comuna, lo que permite asociar cada domicilio del grafo privado a una comuna estandarizada representada en el grafo abierto.

Fuente de Datos

Dataset Privado (no público)

Se construyó un subconjunto de datos sintético y anonimizado inspirado en la operación de una empresa de servicios (MultiSolve), que incluye clientes de tipo organizacional, domicilios o ubicaciones donde se ejecutan los servicios, técnicos responsables, tipos de servicio (por ejemplo, mantenimiento de calefont) y órdenes de servicio que registran fecha, estado, monto y activo intervenido. El dataset no contiene RUT, direcciones reales ni nombres reales; todos los

identificadores y nombres utilizados corresponden a valores ficticios diseñados exclusivamente para fines académicos.

Se utilizó un dataset abierto con comunas de Chile en formato tabular (CSV), con al menos código y nombre de comuna. Este dataset fue transformado a RDF para enlazar domicilios a su comuna mediante un identificador.

Proceso de transformación a RDF

El proceso de transformación a RDF se realizó en dos etapas. En primer lugar, se definió un vocabulario propio para el dominio MultiSolve, con el prefijo *ms:* asociado al namespace *http://example.org/multisolve#*, que incluye clases como *ms:ServiceOrder*, *ms:Customer*, *ms:Technician*, *ms:Location* y *ms:Equipment*, así como propiedades de objeto y de datos específicas. En segundo lugar, se definió un vocabulario para el dataset abierto de comunas con el prefijo *geo:* asociado al namespace *http://example.org/chile-geo#*, con la clase *geo:Comuna* y propiedades como *geo:codigoComuna* y *geo:nombreComuna*.

Ambos namespaces utilizan el dominio *example.org*, reservado comúnmente para ejemplos, lo que resulta apropiado en un contexto académico, ya que los IRIs en RDF no requieren ser URLs dereferenciables para ser válidos, siempre que se mantengan consistentes y estables dentro del modelo. Los registros del sistema interno se transformaron a instancias RDF en el grafo *tarea1-multisolve-private.ttl*, mientras que los registros del CSV de comunas se transformaron en el grafo *tarea1-chile-geo-open.ttl*. La vinculación semántica entre ambos se logra mediante la propiedad *ms:locatedInComuna*, que conecta cada domicilio *ms:Location* con una instancia de *geo:Comuna* correspondiente a su código de comuna.

Modelo de datos RDF

El modelo de datos RDF propuesto combina un vocabulario específico del dominio con la reutilización selectiva de términos de vocabularios estándar. En particular, se definieron clases propias para representar los conceptos de negocio clave: *ms:ServiceOrder* (orden de servicio), *ms:Customer* (cliente), *ms:Technician* (técnico), *ms:ServiceType* (tipo de servicio), *ms:Equipment* (equipo) y *ms:Location* (domicilio), mientras que la clase *geo:Comuna* representa las comunas del dataset abierto.

Para favorecer la interoperabilidad, ciertas clases propias se alinearon con *schema.org*, declarando, por ejemplo, *ms:ServiceOrder* como subclase de *schema:Order*, *ms:Customer* como subclase de *schema:Organization* y *ms:ServiceType* como subclase de *schema:Service*, de acuerdo con la documentación oficial de *schema.org*. Las relaciones entre entidades se expresan mediante propiedades de objeto como *ms:hasCustomer*, *ms:hasLocation*, *ms:hasTechnician*, *ms:hasServiceType*, *ms:hasEquipment*, *ms:installedAt* y *ms:locatedInComuna*. Atributos como identificadores, fechas, códigos y descripciones se modelan mediante propiedades de datos con

rangos en *xsd:string* y *xsd:date*, proporcionando una base clara para la posterior definición de restricciones en ShEx y SHACL.

Validación con ShEx

La validación de los datos se realizó en primer término mediante Shape Expressions (ShEx), definiendo un esquema en formato compacto (*tareal-model.shex*) que especifica la estructura esperada para los nodos principales del grafo. Se definieron shapes para *geo:Comuna*, *ms:Location*, *ms:Customer*, *ms:Technician*, *ms:ServiceType*, *ms:Equipment* y, en particular, un shape principal *<ServiceOrderShape>* asociado a *ms:ServiceOrder*. Este último establece que toda orden de servicio debe contar con un identificador, una fecha de creación, un estado, una prioridad, un cliente, un domicilio, al menos un técnico, un tipo de servicio y, opcionalmente, equipos asociados, con los tipos de datos adecuados y valores enumerados para estado y prioridad.

El esquema ShEx se evaluó conceptualmente sobre el grafo correcto, compuesto por *tareal-multisolve-private.ttl* y *tareal-chile-geo-open.ttl*, verificando que las instancias de *ms:ServiceOrder* cumplen las restricciones declaradas, mientras que las instancias del grafo *tareal-bad-data.ttl* violan intencionadamente varias de ellas. Según la especificación de ShEx y ejemplos de uso disponibles en la literatura, estos esquemas permiten detectar de manera declarativa errores de estructura, tipos de datos y valores fuera de rango en los grafos RDF.

Demostración con datos incorrectos

Para evidenciar la utilidad de la validación, se construyó un grafo de datos incorrectos (*tareal-bad-data.ttl*) que contiene órdenes de servicio, técnicos y domicilios que no cumplen el modelo definido. Entre los errores introducidos se incluyen órdenes de servicio sin fecha de creación, estados con valores no contemplados en el conjunto permitido, prioridades fuera del rango establecido, técnicos sin nombre y domicilios que referencian comunas inexistentes en el grafo de comunas.

Al validar estos recursos contra el esquema ShEx, se espera que el validador reporte múltiples violaciones, tales como incumplimiento de cardinalidades mínimas, valores literales no incluidos en las enumeraciones definidas y fallo en la validación de shapes anidados para ubicaciones y comunas. De esta forma, el grafo con errores funciona como un caso de prueba negativo que ilustra cómo los mecanismos de validación permiten detectar inconsistencias semánticas en los datos, incluso cuando estos son sintácticamente válidos como RDF. Esta estrategia está alineada con las buenas prácticas recomendadas en el uso de lenguajes de validación para RDF.

SHACL

De manera complementaria, se definió un conjunto mínimo de shapes SHACL en el archivo *tareal-model.shacl.ttl*, con el fin de expresar restricciones análogas a las modeladas en ShEx. El

enfoque consiste en declarar un *sh:NodeShape* dirigido a la clase *ms:ServiceOrder*, con propiedades *sh:property* que describen los requisitos de tipo, cardinalidad y dominios de valores para *ms:orderId*, *ms:creationDate*, *ms:status*, *ms:priority*, *ms:hasCustomer*, *ms:hasLocation*, *ms:hasTechnician* y *ms:hasServiceType*.

SHACL se basa en la relación entre un grafo de datos y un grafo de shapes, y su especificación estándar establece los mecanismos formales para emitir informes de validación estructurados ante incumplimientos de las restricciones. Si bien en esta tarea ShEx constituye el mecanismo principal de validación, la incorporación de SHACL aporta una perspectiva complementaria y permite contrastar las ventajas y diferencias de ambos lenguajes en un escenario concreto, lo que resulta pertinente en un contexto de formación de postgrado en Tecnologías de la Información.

Conclusión

La tarea desarrollada demuestra que es posible diseñar y validar de manera sistemática un modelo RDF para un dominio empresarial realista, integrando datos privados y datos abiertos mediante un vocabulario propio y la reutilización selectiva de vocabularios estándar. El caso MultiSolve evidencia la importancia de contar con un modelo explícito de clases y propiedades para representar órdenes de servicio, clientes, técnicos, equipos y ubicaciones, así como la utilidad de apoyarse en datasets públicos de referencia, en este caso las comunas de Chile, para normalizar y enriquecer las dimensiones territoriales de la información.

El uso de ShEx y SHACL como lenguajes de validación permite establecer, de manera declarativa, las restricciones estructurales y de contenido que deben cumplir los grafos de datos, identificando de forma explícita tanto los casos correctos como aquellos que presentan inconsistencias. Esta experiencia resulta formativa en términos académicos, ya que fomenta el razonamiento crítico sobre decisiones de modelado, la trazabilidad entre fuentes originales y grafos RDF y la aplicación rigurosa de estándares de la Web Semántica en contextos de datos empresariales.

Anexos / artefactos entregados

Los artefactos resultantes de la tarea son:

- *tareal-multisolve-private.ttl*: grafo RDF con datos privados sintéticos de MultiSolve.
- *tareal-chile-geo-open.ttl*: grafo RDF derivado del dataset abierto de comunas de Chile.
- *tareal-model.shex*: modelo de validación en Shape Expressions.
- *tareal-bad-data.ttl*: grafo RDF con datos incorrectos para pruebas negativas de validación.
- *tareal-model.shacl.ttl*: modelo de validación en SHACL.